## 애저 쿠버네티스 서비스 실전 201

Microsoft App Dev CSA

# AKS Compute 심화

Microsoft App Dev CSA

# AKS Compute 심화 - 2

Microsoft App Dev CSA

## AKS Network 심화 - 1

Microsoft App Dev CSA

## AKS Network 심화 - 2

Microsoft App Dev CSA

# AKS Volume 심화

Microsoft App Dev CSA

# K8S Cluster를 프로덕션 환경에 부드럽게 랜딩 시키기

Sailing Smoothly on K8S

Microsoft App Dev CSA

Inhye Park

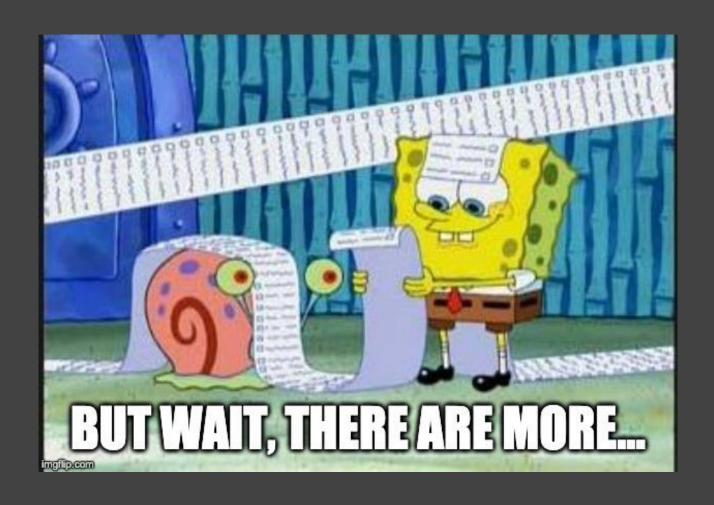
2020/11/12

### 가장 흔하게 겪는 고객 이슈

메모리 overload

**IO** overload

SNAT 포트 고갈 & 쿼터 부족



# 메모리 Overload

- ➤ 메모리 overload
- IO overload
- SNAT 포트 고갈 & 쿼터 부족

#### 증상

유저 Pod가 evict 됨

유저 Pod가 OOMKilled 됨

Kube-system Pod가 evict 됨

노드가 순간적으로 taint되어 스케줄링 할 수 없음

### 관측 (1)

Limit 이 설정되어 있지 않음

- name: JAVA\_OPTS

value: "-Xmx2g"

Describe pod:

Status: Failed

Reason: **Evicted** 

Message: The node had condition: [MemoryPressure]

• • • •

**Events:** 

default-scheduler 0/3 nodes are available: 3 node(s) had **taints** that the pod didn't tolerate.

Describe node:

Taints: node.kubernetes.io/memory-pressure:NoSchedule

status is now: NodeHasInsufficientMemory

### 관측 (2)

Limit은 설정되어 있는데 너무 낮게 설정되어 있을 때.

- name: JAVA\_OPTS

value: "-Xmx1g"

resources:

requests:

memory: "250Mi"

cpu: "250m"

limits:

memory: "500Mi"

cpu: "500m"

State: Waiting

Reason: CrashLoopBackOff

Last State: Terminated

Reason: **OOMKilled** 

Exit Code: 137

### 관측 (3)

중요한 kube-system namespace 의 system pod가 eviction 되는 현상. 클러스터가 순간적으로 unstable/ unusable 상태가 될 수 있음

kube-system metrics-server-566bd9b4f7-gp9nt 1/1 Running 0 31m kube-system metrics-server-566bd9b4f7-zd8lm 0/1 Evicted 0 16h

#### 메모리: Best practices

모든 컨테이너마다 resource request 와 limit 을 설정해라 네임스페이스에 ResourceQuota와 LimitRange를 설정해라 System critical pod는 dedicated node pool로 Isolation 시켜라 충분한 core와 memory 여유분을 준비해 놓자 모든 kube-system pods는 이미 "CriticalAddonsOnly" 로 toleration 되어 있다.

### 10 overload

- 메모리 overload
- > IO overload
- SNAT 포트 고갈 & 쿼터 부족

#### 증상

AKS 클러스터 노드들의 상태가 NotReady로 빠짐

API Server와 통신할 때 "TLS handshake timeout" 에러 발생

Kube-proxy, coreDNS 같은 중요한 Daemonsets 또는 pods가 fail 상태가 됨

istio 혹은 복잡한 operator configuration 사용시 퍼포먼스와 안정성에 이슈가 발생됨

다른 Azure Service 와 통신할 때 네트워킹 에러 혹은 높은 latency 로 성능 저하가 발생됨

DNS 쿼리가 늦어짐

노드에 PLEG (pod lifecycle event generator) 에러가 발생됨

kubelet/docker 로그에 "RPC context deadline exceeded" 에러가 발생함

PV attach/detach 가 늦게 됨

### 관측 (1)

#### Max IOPS는 VM과 OS disk IOPS 중 낮은 것을 따른다.

AKS OS disks는 리모트 디스크

Small OS disk는 낮은 IOPS와 throughput를 제공함

L	VM Si↑↓	Offering $\uparrow_{\downarrow}$	Family	$\uparrow_{\downarrow}$	vCP↑↓	<b>RAM (</b> ↑↓	Data disks ↑↓	Max IOPS $\uparrow_{\downarrow}$	Temporary stor $\uparrow \downarrow$	Premium disk s↑↓	Cost/month (es↑↓
	DS1_v2	Standard	General purpose		1	3.5	4	3200	7	Yes	\$42.41
	DS2_v2	Standard	General purpose		2	7	8	6400	14	Yes	\$84.82
	DS3_v2	Standard	General purpose		4	14	16	12800	28	Yes	\$170.38

Premium SSD sizes	P1*	P2*	P3*	P4	P6	P10
Disk size in GiB	4	8	16	32	64	128
IOPS per disk	120	120	120	120	240	600

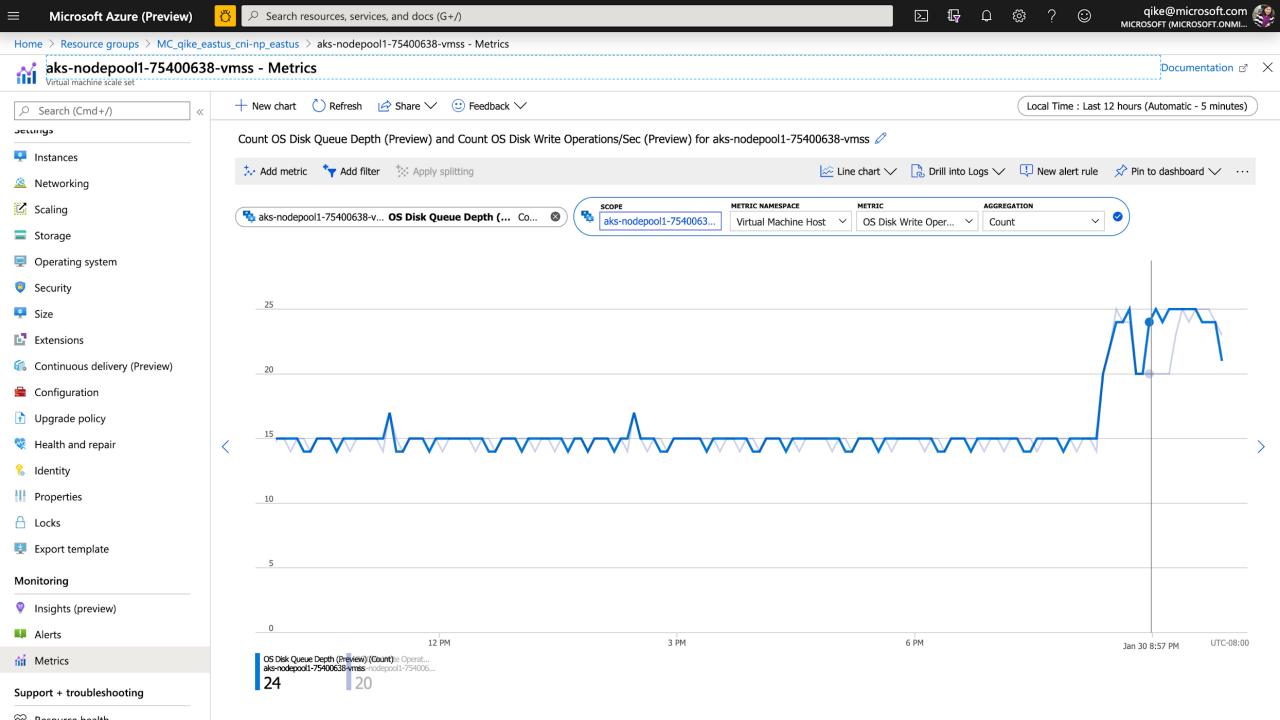
### 관측 (2)

#### Usually triggered by:

노드에서 운영되어지고 있는 Containers가 매우 많거나 Container image 사이즈가 클 때로그 기능을 Aggressive하게 사용 할 경우 (e.g. 3rd party 로깅 시스템, 모니터링, audit tools 사용시) OS disk를 data disk처럼 사용할 때(in workload)

#### Observations (3)

Disk queue depth is an indicator that the OS disk for you worker nodes is throttled.



#### **IO:** Best practices

OS disk를 data disk처럼 사용하지 말기. 대신에, Persistent Volume을 사용해라.

충분한 사이즈의 OS disk를 사용해야.

Ephemeral OS Disk를 사용해라 (once it is out).

Knode를 사용하여 docker data-drive를 ephemeral disk에 mount 하여 사용해라.

Splunk, logstash, filesystem scanners 그리고 container scanners와 같은 3rd party add-ons 을 사용할 때 I/O를 모니터링 해라

OS disks의 모니터링 값에 alert 을 추가해라

More fun details here: https://aka.ms/aks/io-throttle-issue

### SNAT 포트 고갈

- 메모리 overload
- IO overload
- ➤ SNAT 포트 고갈 & 쿼터 부족

#### **Symptoms**

간헐적인 DNS resolution 실패.

API 서버에 연결할 수 없어 노드가 NotReady로 표시됨

Pod가 API server 혹은 other network addresses와 통신할 때 "i/o timeout"에 해당하는 에러를 얻게 됨

E0124 10:08:30.169432 1 reflector.go:134] github.com/coredns/coredns/plugin/kubernetes/controller.go:317: Failed to list \*v1.Endpoints: Get https://xxxx.hcp.eastus.azmk8s.io:443/api/v1/endpoints?limit=500&resourceVersion=0: dial tcp

20.44.xx.xx:443: i/o timeout

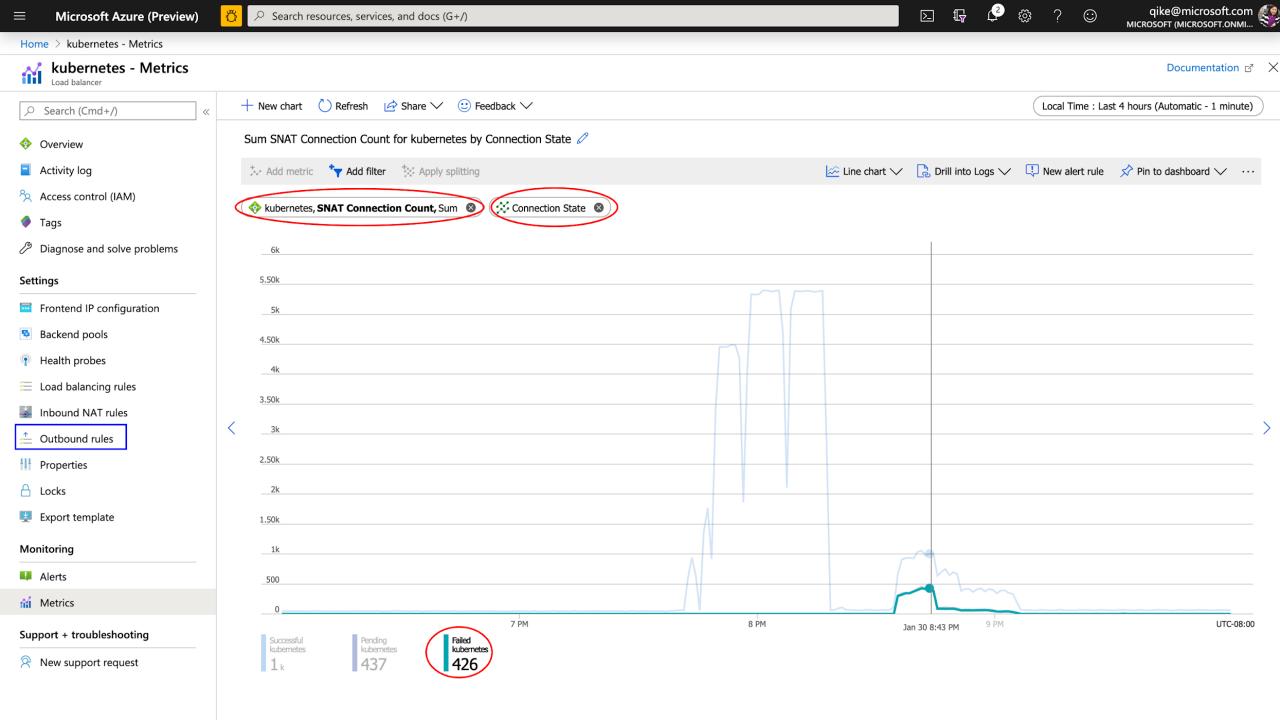
#### SNAT 포트 고갈: 해결책

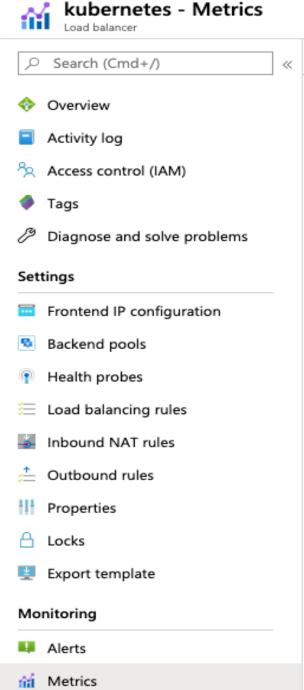
frontend IP를 증가해라.

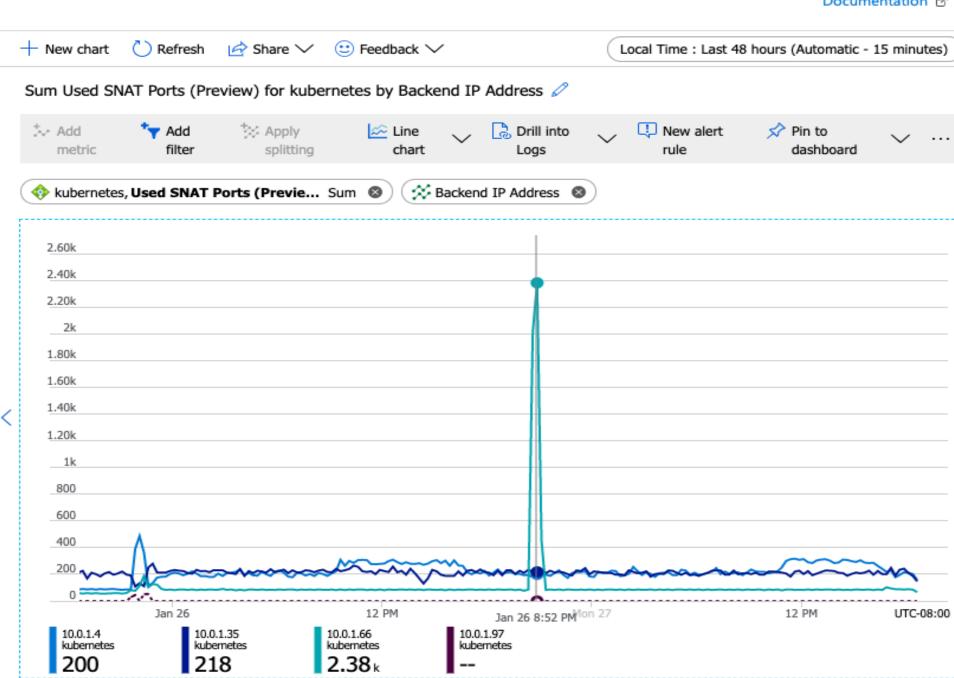
VM마다의 outbound ports를 증가시켜라.

"SNAT connection" 의 failed 항목을 모니터링해라

"Backend IP Addresses"로 디바이드하여 "Used SNAT Ports" 메트릭 항목을 모니 터링해라







# 쿼터부족

- 메모리 overload
- IO overload
- SNAT 포트 고갈 & 쿼터 부족

#### 증상

Cluster auto-scaling fails

Manual scaling fails

Upgrade fails

### 관측

Cluster upgrade requires at least one more VM (with CPU, GPU, IP).

Using Azure CNI requires additional IPs from the subnet. For each additional node, maxPod + 1 IP addresses are needed.

Higher reliability can cost more, such as using blue/green deployment.

\$ az aks scale -g qike\_rg -n cni-cluster -c 10

Deployment failed. Correlation ID: 98d0c9a1-edb0-414b-9518-xxxxxxxx. VMSSAgentPoolReconciler retry failed: Code="SubnetIsFull" Message="Subnet subnet\_cni\_2 with address prefix 10.0.1.0/24 does not have enough capacity for 155 IP addresses."

#### **Quota: Best practices**

Plan ahead.

Request quota in advance. Sometimes quota can be hard to grant when the inventory in the particular region is low.

Architect the service to run in multiple regions and easy to migrate.

